

4. Modelo de calidad de datos

DQ Problems	DQ Dimension	DQ Factor	DQ Metric	DQ method	Applied DQ method
	ID: D4_Unicidad Name: Unicidad Description: Evalúa si los registros en un conjunto de datos son únicos y no presentan duplicaciones no deseadas Suggested by = {RN2, RN5}	ID: Name: No duplicación Description: Porcentaje de datos que no están duplicados en forma exacta Represents = {RN2, RN5}	ID: M_duplicate_ratio Name: duplicate_ratio Description: Da el porcentaje de valores duplicados. Influenced by = {RN2, RN5} Granularity: Columna Result domain = [0...1]	ID: metodo_duplicate_ratio Name: met_duplicate_ratio Description: Implementa la metrica duplicate_ratio sobre un atributo dado. Uses = {RN2, RN5} Input data types: String Output data types: Float Algorithm: <pre>"def duplicate_ratio(data, column): total = len(data) duplicated = data.duplicated(subset=[column]).sum() return duplicated / total"</pre>	ID: MA_duplicate_ratio Type: Medición Description: Dados los datos y el atributo, calcula el porcentaje de valores duplicados en ese atributo. AppliedTo: Atributos «ISBN», «AuthorID», «PublisherID», «User_ID» de la tabla NL_Books. Atributos «ID» de la tabla NL_USERS."

DQ Problems	DQ Dimension	DQ Factor	DQ Metric	DQ method	Applied DQ method
P11	ID: D2_Compleitud Name: Compleitud Description: Indica si el sistema de información contiene toda la información de interés. Suggested by = {RN1, RN2, RN5, RQ3, RQ7, F2}	ID: F2_Dens Name: Densidad Description: Indica cuanta información se tiene y cuanta falta sobre las entidades del sistema de información. Represents = {RN1, RN2, RN5, RQ3, RQ7, F2}	ID: M_contar_nulls Name: contar_nulls Description: Calcula el porcentaje de entradas vacias en una columna Influenced by = {RN1, RN5, RQ3, RQ7, F2} Granularity: Columna Result domain = {0, 1}	ID: metodo_contar_nulls Name: met_contar_nulls Description: Implementa la metrica contar_nulls. Uses = {RN1, RN5, RQ3, RQ7, F2} Input data types: String Output data types: Float Algorithm: <pre>"def porcentaje_nulos(atributo): nulos = atributo.isnull() contador_nulos = nulos.sum() porcentaje = contador_nulos / len(atributo) return porcentaje"</pre>	ID: MA_contar_nulls Type: Medición Description: Dado un atributo de una tabla, calcula el porcentaje de entradas vacias. AppliedTo: Cualquier atributo de cualquier tabla.
			ID: M_check_RN1 Name: check_RN1 Description: Da el porcentaje de entradas de la tabla que tienen al menos un campo vacío entre los atributos isbn, título, autor y editor. Influenced by = {RN1, RN2, RQ3, RQ7, F2} Granularity: Conjunto de columnas Result domain = [0...1]	ID: metodo_check_RN1 Name: met_check_RN1 Description: Implementa la metrica Check_RN1 sobre una tabla dada. Uses = {RN1, RN2, RQ3, RQ7, F2} Input data types: String Output data types: Float Algorithm: <pre>"def Check_RN1(datos): # Seleccionar solo las columnas relevantes (isbn, titulo, autor, editor) datos_relevantes = datos[['isbn', 'titulo', 'autor', 'editor']] # Verificar cuántas filas tienen al menos un campo NULL entre estas columnas incompletos = datos_relevantes.isnull().any(axis=1).sum() # Calcular la proporción de filas incompletas return incompletos / len(datos)"</pre>	ID: MA_check_RN1 Type: Medición Description: Dada una tabla, calcula el porcentaje de entradas que tienen al menos un campo vacío entre los atributos isbn, título, autor y editor. AppliedTo: Tabla NL_Books.

DQ Problems	DQ Dimension	DQ Factor	DQ Metric	DQ method	Applied DQ method
	ID: D3_Consistencia Name: Consistencia Description: Captura la satisfacción de reglas semánticas definidas sobre los datos. Suggested by = {RQ4, RQ6, RQ8, RQ11, F1, F3}	ID: Name: Integridad inter-relación Description: Captura la satisfacción de reglas entre atributos de tablas distintas. Represents = {RQ4, RQ6, RQ8, RQ11, F1, F3}	ID: M_consistencia_ratings Name: concistencia_ratings Description: Verifica que la cantidad de ratings entre las distintas tablas sea coherente. Influenced by = {RQ8} Granularity: conjunto de columnas Result domain = {0, 1}	ID: metodo_consistencia_ratings Name: met_consistencia_ratings Description: Implementa la metrica concistencia_ratings contando la cantidad de ocurrencias de un ISBN valido en la tabla NL_ratings y lo compara con lo declarado en el atributo rating_count de NL_Books. Uses = {RQ8} Input data types: String Output data types: Boolean Algorithm: <pre> "def función consistencia_ratings(libros, valid_isbn, ratings): libros_validos = libros[valid_isbn==True] for libro in libros_validos: isbn = libro['isbn'] cantidad = (ratings['isbn'] == isbn).sum() contados[isbn] = cantidad rating_esperado = libros_validos['rating_counts'] return rating_esperado==contados" </pre>	ID: MA_consistencia_ratings Type: Agregación Description: Dada una tabla de reviews, una tabla de libros (ambas con el campo isbn) y una lista que indiquen si son validos o no, determina si hay congruencia entre lo registrado en ambas tablas sobre los ratings. AppliedTo: Conjunto de atributos (NL_ratings.ISBN, NL_books.ISBN, NL_books.Rating_Count)
			ID: M_consistencia_fechas Name: concistencia_fechas Description: Verifica que la fecha de un rating sea posterior a la fecha de publicación del libro. Influenced by = {RQ6, RQ11, F1} Granularity: Conjunto de columnas Result domain = {0, 1}	ID: metodo_consistencia_fechas Name: met_consistencia_fechas Description: Implementa la metrica concistencia_fechas comparando las fechas de review_time de la tabla NL_reviews y la de PublisherDate de NL_Books. Uses = {RQ6, RQ11, F1} Input data types: String Output data types: Boolean Algorithm: <pre> "def consistencia_fechas(NL_reviews, NL_books): result = lista vacia for (i ; i< len(NL_reviews); i++): isbn = NL_reviews['isbn'][i] fila_libro = fila en NL_books donde NL_books['isbn']==isbn obtener los review_time y PublishedDate de las filas correspondientes result[i] = review_time >= PublishedDate: return resut" </pre>	ID: MA_consistencia_fechas Type: Medición Description: Dada una tabla de reviewsy una tabla de libros (ambas con el campo isbn), determina si la fecha de la review es posterior a la publicación del libro. AppliedTo: Conjunto de atributos «NL_Reviews.review_time, NL_Books.PublisherDate»
			ID: M_missing_rating_books Name: missing_rating_books Description: Para ratings sobre libros, controla la existencia de estos en la base de datos. Influenced by = {RQ4, RQ8, F3} Granularity: Celda Result domain = {0, 1}	ID: metodo_missing_rating_books Name: met_missing_rating_books Description: Implementa la metrica check_rating_books para ver si los libros indicados en los ratings existen. Uses = {RQ4, RQ8, F3} Input data types: String Output data types: Boolean Algorithm: <pre> "SELECT COUNT(*) FROM NL_Ratings WHERE NOT EXISTS(SELECT * FROM NL_Books WHERE NL_Ratings.ISBN = NL_Books.ISBN)" </pre>	ID: MA_missing_rating_books Type: Medición Description: Verifica que el libro en NL_Ratings exista en NL_Books mediante una consulta SQL. AppliedTo: Conjunto de atributos «ISBN» en las tablas NL_Books y NL_Ratings

DQ Problems	DQ Dimension	DQ Factor	DQ Metric	DQ method	Applied DQ method
P1, P2, P5, P6, P8, P14.	ID: D1_Exactitud Name: Exactitud Description: Conciérne a la correctitud y la precisión con que los datos del mundo real son representados en un sistema de información. Suggested by = {RN1, RN2, RN4, RQ2, RQ3, RQ6, RQ11, F1}	ID: F1_ExactSint Name: Exactitud sintáctica Description: Indica que tan libre de errores sintácticos están los datos. Represents = {RN1, RN2, RQ3, RN4, RQ2}	ID: M_check_ISBN Name: check_ISBN Description: Controla si el valor es un ISBN valido. Influenced by = {RN1, RN2, RQ3} Granularity: Celda Result domain = {0, 1}	ID: metodo_check_ISBN Name: met_check_ISBN Description: Implementa la métrica Check_ISBN teniendo en cuenta la estructura de un código ISBN. Uses = {RN1, RN2, RQ3} Input data types: String Output data types: Boolean Algorithm: <pre> def Check_ISBN(codigo): size = len(codigo) # Chequea para el caso de un ISBN10 if (size==10): verifica que los primeros 9 caracteres sean digitos verifica que el ultimo caracter sea un digito o una "X" verifica que el digito verificador sea correcto # Chequea para el caso de un ISBN10 if (size==13): verifica que todos los caracteres sean digitos verifica que el digito verificador sea correcto" </pre>	ID: MA_check_ISBN Type: Medición Description: Utiliza el algoritmo de calculo de ISBN para verificar la validez del dato. AppliedTo: Atributo «ISBN» de la tabla NL_Books
			ID: M_check_edades Name: check_edades Description: Controla si la edad es valida. Influenced by = {RN4, RQ2} Granularity: Celda Result domain = {0, 1}	ID: metodo_check_edades Name: met_check_edades Description: Implementa la metrica Check_edades verificando si la edad tiene formato correcto y es un valor razonable. Uses = {RN4, RQ2} Input data types: String Output data types: Boolean Algorithm: IsNumeric(edad) AND edad > 0 AND edad < 100	ID: MA_check_edades Type: Medición Description: Verifica que tenga un valor numerico entre 1 y 99 AppliedTo: Atributo «Age» de la tabla NL_Users
			ID: M_check_price Name: check_price Description: Controla si la precio es valido. Influenced by = {RN3} Granularity: Celda Result domain = {0, 1}	ID: metodo_check_price Name: met_check_price Description: Implementa la metrica check_price verificando si el valor tiene formato correcto Uses = {RN3} Input data types: String Output data types: Boolean Algorithm: IsNumeric(price) AND price >= 0	ID: MA_check_price Type: Medición Description: Verifica que tenga un valor numerico positivo con una consulta SQL AppliedTo: Atributo «Price» de la tabla NL_Books
			ID: M_duplicated_authors Name: duplicated_authors Description: Indica cuantas tuplas nombran mas de 1 autor. Influenced by = {RN1, RQ3} Granularity: Columna Result domain = [0..1]	ID: metodo_duplicated_authors Name: met_duplicated_authors Description: Implementa la metrica duplicated_author para obtener el porcentaje de tuplas que indican mas de 1 autor Uses = {RN1, RQ3} Input data types: String Output data types: Double Algorithm: <pre> DEFINE @tuplasDuplicadas = SELECT COUNT(*) FROM NL_Authors WHERE AuthorID LIKE '%,%' DEFINE @tuplasTotales = SELECT COUNT(*) FROM NL_Authors SELECT @tuplasDuplicadas / @tuplasTotales </pre>	ID: MA_duplicated_authors Type: Medición Description: Divide las tuplas que indican mas de 1 autor sobre las tuplas totales AppliedTo: Atributo «AuthorID» en la tabla NL_Books

DQ Problems	DQ Dimension	DQ Factor	DQ Metric	DQ method	Applied DQ method
P1, P2, P5, P6, P8, P14.	ID: D1_Exactitud Name: Exactitud Description: Conciérne a la correctitud y la precisión con que los datos del mundo real son representados en un sistema de información. Suggested by = {RN1, RN2, RN4, RQ2, RQ3, RQ6, RQ11, F1}	ID: F3_Precision Name: Exactitud precisión Description: Indica que tan detallados son los datos. Represents = {RQ6, RQ11, F1}	ID: M_date_format Name: date_format Description: Controla el formato de fecha de todas las columnas tipo fecha. Influenced by = {RQ6, RQ11, F1} Granularity: Celda Result domain = {0, 1}	ID: metodo_date_format Name: met_date_format Description: Implementa la metrica date_format para controlar que el formato de fecha sea correcto Uses = {RQ6, RQ11, F1} Input data types: String Output data types: Boolean Algorithm: TRY_CONVERT(DATE,date,103)	ID: MA_date_format Type: Medición Descriptinon: Verifica que el campo PublisherDate en Books y el campo review_time en Ratings respeten el formato correcto de fecha dd/mm/yyyy AppliedTo: Atributo «PublisherDate» en la tabla NL_Books y atributo «review_time» en al tabla NL_Ratings